Universidad de Sonora

Reconocimiento de patrones: Preparación de los datos

Ramón Soto C. (rsotoc@moviquest.com)

Limpieza de los datos

La limpieza de datos es el proceso de identificar y corregir o eliminar imperfecciones en un conjunto de datos. Las actividades típicas en esta fase son rellenar valores faltantes, suavizar ruido, identificar y remover valores atípicos y resolver inconsistencias.

Valores faltantes

El problema de valores faltantes es un problema muy frecuente al tratar de realizar cualquier tarea de análisis de datos y puede deberse a diversas razones:

- Fallas en los mecanismos de medición (sensores defectuosos, por ejemplo)
- Integración de conjuntos de datos no bien coordinados (mediciones con diferentes ciclos, por ejemplo)
- Variables nuevas no consideradas o no disponibles originalmente
- Respuestas omitidas intencionalmente por la fuente

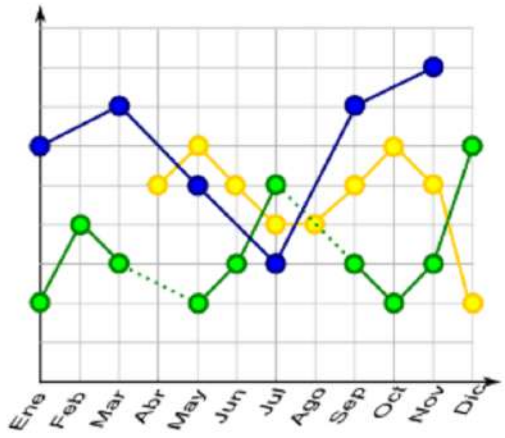

La omisión de valores en el conjunto de datos puede tener diversos efectos y diferentes grados de impacto. En términos generales, se suelen considerar los siguientes grados de impacto, dependiendo del porcentaje de valores faltantes (*dumb rules*):

- Menos de 1%: Trivial (no relevante)
- 1-5%: Manejable
- 5-15%: Manejable mediante métodos sofisticados
- Más de 15%: Crítico, con impacto severo en cualquier tipo de interpretación

Considérese el siguiente conjunto de datos tomados del conjunto de datos de diabetes:

In [1]:
```
"""
Reconocimiento de patrones: Limpieza de datos
"""

import numpy as np
import pandas as pd

path = 'Data sets/Pima Indian Data Set/'
```

In [2]:
```
df = pd.read_csv(path + "pima-indians-diabetes.data-small",
                 names = ['emb', 'gl2h', 'pad', 'ept', 'is2h', 'imc', 'fpd', 'edad', 'class'])

print(df.describe(), '\n')
print(df)
```

```
             emb        gl2h        pad        ept        is2h        imc  \
count  20.00000   20.000000  18.000000  11.000000    9.000000  19.000000
mean    4.50000  129.400000  68.555556  32.363636  258.111111  32.578947
std     3.56149   35.354446  16.346333   8.891262  263.487877   6.509103
min     0.00000   78.000000  30.000000  19.000000   83.000000  23.300000
25%     1.00000  106.000000  64.500000  26.000000   94.000000  27.600000
50%     4.50000  117.000000  71.000000  32.000000  168.000000  30.500000
75%     7.25000  152.500000  74.000000  36.500000  230.000000  36.450000
max    10.00000  197.000000  96.000000  47.000000  846.000000  45.800000

             fpd       edad     class
count  20.000000  20.000000  20.00000
mean    0.511650  37.450000   0.65000
std     0.513691  11.591626   0.48936
min     0.134000  21.000000   0.00000
25%     0.198500  30.750000   0.00000
50%     0.374500  32.000000   1.00000
75%     0.560000  50.250000   1.00000
max     2.288000  59.000000   1.00000

    emb  gl2h   pad   ept   is2h   imc    fpd  edad  class
0     6   148  72.0  35.0    NaN  33.6  0.627    50      1
1     1    85  66.0  29.0    NaN  26.6  0.351    31      0
2     8   183  64.0   NaN    NaN  23.3  0.672    32      1
3     1    89  66.0  23.0   94.0  28.1  0.167    21      0
4     0   137  40.0  35.0  168.0  43.1  2.288    33      1
5     5   116  74.0   NaN    NaN  25.6  0.201    30      0
6     3    78  50.0  32.0   88.0  31.0  0.248    26      1
7    10   115   NaN   NaN    NaN  35.3  0.134    29      0
8     2   197  70.0  45.0  543.0  30.5  0.158    53      1
9     8   125  96.0   NaN    NaN   NaN  0.232    54      1
10    4   110  92.0   NaN    NaN  37.6  0.191    30      0
11   10   168  74.0   NaN    NaN  38.0  0.537    34      1
12   10   139  80.0   NaN    NaN  27.1  1.441    57      0
13    1   189  60.0  23.0  846.0  30.1  0.398    59      1
14    5   166  72.0  19.0  175.0  25.8  0.587    51      1
15    7   100   NaN   NaN    NaN  30.0  0.484    32      1
16    0   118  84.0  47.0  230.0  45.8  0.551    31      1
17    7   107  74.0   NaN    NaN  29.6  0.254    31      1
18    1   103  30.0  38.0   83.0  43.3  0.183    33      0
19    1   115  70.0  30.0   96.0  34.6  0.529    32      1
```

Como puede observarse, la variable *count* no es la misma para todas las columnas. Comparando con el despliegue de los datos, las diferencias en el valor de esta variable corresponden a los valores faltantes. Una mayor exploración podemos obtenerla de la siguiente manera:

In [3]:
```
print ('Tabla de valores nulos')
print (df.isnull(), '\n')

print ('Contabilidad de valores nulos por columna')
print (df.isnull().sum(), '\n')

print ('Porcentaje de datos nulos en la columna *ept*')
eptNullPje = df['ept'].isnull().sum() / df.shape[0] * 100
print (eptNullPje)
```

```
Tabla de valores nulos
      emb   gl2h    pad    ept   is2h    imc    fpd   edad  class
0   False  False  False  False   True  False  False  False  False
1   False  False  False  False   True  False  False  False  False
2   False  False  False   True   True  False  False  False  False
3   False  False  False  False  False  False  False  False  False
4   False  False  False  False  False  False  False  False  False
5   False  False  False   True   True  False  False  False  False
6   False  False  False  False  False  False  False  False  False
7   False  False   True   True   True  False  False  False  False
8   False  False  False  False  False  False  False  False  False
9   False  False  False   True   True   True  False  False  False
10  False  False  False   True   True  False  False  False  False
11  False  False  False   True   True  False  False  False  False
12  False  False  False   True   True  False  False  False  False
13  False  False  False  False  False  False  False  False  False
14  False  False  False  False  False  False  False  False  False
15  False  False   True   True   True  False  False  False  False
16  False  False  False  False  False  False  False  False  False
17  False  False  False   True   True  False  False  False  False
18  False  False  False  False  False  False  False  False  False
19  False  False  False  False  False  False  False  False  False

Contabilidad de valores nulos por columna
emb       0
gl2h      0
pad       2
ept       9
is2h     11
imc       1
fpd       0
edad      0
class     0
dtype: int64

Porcentaje de datos nulos en la columna *ept*
45.0
```

El porcentaje de valores faltantes en este segmento de datos (45% de valores faltantes) está muy por encima de lo que puede tratarse de manera directa, según las reglas anteriores.

Identificación de valores faltantes

En muchos casos, incluso detectar los valores faltantes es un problema. En nuestros datos originales, lo valores faltantes vienen enmascarados como 0, no como un espacio vacío. En este caso, el procedimiento anterior fallaría pues no existen datos 'no disponibles'. Debemos primero analizar los datos y detectar cómo se manifiestan los valores faltantes. En nuestro ejemplo, asumimos que *ept*, esto es, el 'Espesor de la piel del tríceps' no puede tener un valor de 0 y, por lo tanto, ese valor representa un valor faltante.

In [4]:
```
df2 = pd.read_csv(path + "pima-indians-diabetes.data-small-orig",
                  names = ['emb', 'gl2h', 'pad', 'ept', 'is2h', 'imc', 'fpd', 'edad', 'class'])
print(df2, '\n')
```

	emb	gl2h	pad	ept	is2h	imc	fpd	edad	class
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	0	137	40	35	168	43.1	2.288	33	1
5	5	116	74	0	0	25.6	0.201	30	0
6	3	78	50	32	88	31.0	0.248	26	1
7	10	115	0	0	0	35.3	0.134	29	0
8	2	197	70	45	543	30.5	0.158	53	1
9	8	125	96	0	0	0.0	0.232	54	1
10	4	110	92	0	0	37.6	0.191	30	0
11	10	168	74	0	0	38.0	0.537	34	1
12	10	139	80	0	0	27.1	1.441	57	0
13	1	189	60	23	846	30.1	0.398	59	1
14	5	166	72	19	175	25.8	0.587	51	1
15	7	100	0	0	0	30.0	0.484	32	1
16	0	118	84	47	230	45.8	0.551	31	1
17	7	107	74	0	0	29.6	0.254	31	1
18	1	103	30	38	83	43.3	0.183	33	0
19	1	115	70	30	96	34.6	0.529	32	1

Para resolver el problema, debemos preparar los datos asignando una etiqueta *NaN* a los valores que consideramos como valores 'faltantes':

In [5]:
```
df2.loc[df2['ept'] == 0,'ept'] = np.nan
print(df2)
```

	emb	gl2h	pad	ept	is2h	imc	fpd	edad	class
0	6	148	72	35.0	0	33.6	0.627	50	1
1	1	85	66	29.0	0	26.6	0.351	31	0
2	8	183	64	NaN	0	23.3	0.672	32	1
3	1	89	66	23.0	94	28.1	0.167	21	0
4	0	137	40	35.0	168	43.1	2.288	33	1
5	5	116	74	NaN	0	25.6	0.201	30	0
6	3	78	50	32.0	88	31.0	0.248	26	1
7	10	115	0	NaN	0	35.3	0.134	29	0
8	2	197	70	45.0	543	30.5	0.158	53	1
9	8	125	96	NaN	0	0.0	0.232	54	1
10	4	110	92	NaN	0	37.6	0.191	30	0
11	10	168	74	NaN	0	38.0	0.537	34	1
12	10	139	80	NaN	0	27.1	1.441	57	0
13	1	189	60	23.0	846	30.1	0.398	59	1
14	5	166	72	19.0	175	25.8	0.587	51	1
15	7	100	0	NaN	0	30.0	0.484	32	1
16	0	118	84	47.0	230	45.8	0.551	31	1
17	7	107	74	NaN	0	29.6	0.254	31	1
18	1	103	30	38.0	83	43.3	0.183	33	0
19	1	115	70	30.0	96	34.6	0.529	32	1

En plataformas para *data science*, como R y Pandas, los valores marcados como 'NaN' suelen ser ignorados en las operaciones:

In [6]:
```
print(df2.info(), '\n')

print(df2.describe(), '\n')

print('Suma y promedio de ept: ({}, {})'.format(df2['ept'].sum(), df2['ept'].mean()), '\n')

print('Promedio tomando en cuenta los 0s:', df2['ept'].sum()/20)
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20 entries, 0 to 19
Data columns (total 9 columns):
emb      20 non-null int64
gl2h     20 non-null int64
pad      20 non-null int64
ept      11 non-null float64
is2h     20 non-null int64
imc      20 non-null float64
fpd      20 non-null float64
edad     20 non-null int64
class    20 non-null int64
dtypes: float64(3), int64(6)
memory usage: 1.5 KB
None

             emb        gl2h        pad        ept        is2h        imc  \
count  20.00000   20.000000  20.000000  11.000000   20.000000  20.000000
mean    4.50000  129.400000  61.700000  32.363636  116.150000  30.950000
std     3.56149   35.354446  26.159631   8.891262  215.843821   9.654424
min     0.00000   78.000000   0.000000  19.000000    0.000000   0.000000
25%     1.00000  106.000000  57.500000  26.000000    0.000000  26.975000
50%     4.50000  117.000000  70.000000  32.000000    0.000000  30.300000
75%     7.25000  152.500000  74.000000  36.500000  114.000000  35.875000
max    10.00000  197.000000  96.000000  47.000000  846.000000  45.800000

             fpd       edad     class
count  20.000000  20.000000  20.00000
mean    0.511650  37.450000   0.65000
std     0.513691  11.591626   0.48936
min     0.134000  21.000000   0.00000
25%     0.198500  30.750000   0.00000
50%     0.374500  32.000000   1.00000
75%     0.560000  50.250000   1.00000
max     2.288000  59.000000   1.00000

Suma y promedio de ept: (356.0, 32.36363636363637)

Promedio tomando en cuenta los 0s: 17.8
```

Tratamiento de valores faltantes

El método más simple para tratar con el problema de valores faltantes es la *eliminación de casos*, también conocido como *análisis de casos completos. Este método está disponible en todos los paquetes de análisis de datos y es la opción por omisión en la mayoría.

En Pandas podemos eliminar los valores faltantes de diferentes maneras. *DataFrame.dropna*() elimina todos los renglones en el DataFrame en los que hay al menos un valor *NaN*:

In [7]:
```
print(df, '\n')
print(df.dropna())
```

	emb	gl2h	pad	ept	is2h	imc	fpd	edad	class
0	6	148	72.0	35.0	NaN	33.6	0.627	50	1
1	1	85	66.0	29.0	NaN	26.6	0.351	31	0
2	8	183	64.0	NaN	NaN	23.3	0.672	32	1
3	1	89	66.0	23.0	94.0	28.1	0.167	21	0
4	0	137	40.0	35.0	168.0	43.1	2.288	33	1
5	5	116	74.0	NaN	NaN	25.6	0.201	30	0
6	3	78	50.0	32.0	88.0	31.0	0.248	26	1
7	10	115	NaN	NaN	NaN	35.3	0.134	29	0
8	2	197	70.0	45.0	543.0	30.5	0.158	53	1
9	8	125	96.0	NaN	NaN	NaN	0.232	54	1
10	4	110	92.0	NaN	NaN	37.6	0.191	30	0
11	10	168	74.0	NaN	NaN	38.0	0.537	34	1
12	10	139	80.0	NaN	NaN	27.1	1.441	57	0
13	1	189	60.0	23.0	846.0	30.1	0.398	59	1
14	5	166	72.0	19.0	175.0	25.8	0.587	51	1
15	7	100	NaN	NaN	NaN	30.0	0.484	32	1
16	0	118	84.0	47.0	230.0	45.8	0.551	31	1
17	7	107	74.0	NaN	NaN	29.6	0.254	31	1
18	1	103	30.0	38.0	83.0	43.3	0.183	33	0
19	1	115	70.0	30.0	96.0	34.6	0.529	32	1

	emb	gl2h	pad	ept	is2h	imc	fpd	edad	class
3	1	89	66.0	23.0	94.0	28.1	0.167	21	0
4	0	137	40.0	35.0	168.0	43.1	2.288	33	1
6	3	78	50.0	32.0	88.0	31.0	0.248	26	1
8	2	197	70.0	45.0	543.0	30.5	0.158	53	1
13	1	189	60.0	23.0	846.0	30.1	0.398	59	1
14	5	166	72.0	19.0	175.0	25.8	0.587	51	1
16	0	118	84.0	47.0	230.0	45.8	0.551	31	1
18	1	103	30.0	38.0	83.0	43.3	0.183	33	0
19	1	115	70.0	30.0	96.0	34.6	0.529	32	1

El parámetro *tresh* en DataFrame.dropna() permite eliminar todos los renglones que no contengan al menos el número de columnas "limpias" expresado por el parámetro. En los ejemplos a continuación, se conservan 1) sólo los renglones que tienen al menos 8 columnas *limpias* y 2) los renglones que tienen al menos 7 columnas con valores definidos:

In [8]:
```
print(df.dropna(thresh=8), '\n')
print(df.dropna(thresh=7))
```

	emb	gl2h	pad	ept	is2h	imc	fpd	edad	class
0	6	148	72.0	35.0	NaN	33.6	0.627	50	1
1	1	85	66.0	29.0	NaN	26.6	0.351	31	0
3	1	89	66.0	23.0	94.0	28.1	0.167	21	0
4	0	137	40.0	35.0	168.0	43.1	2.288	33	1
6	3	78	50.0	32.0	88.0	31.0	0.248	26	1
8	2	197	70.0	45.0	543.0	30.5	0.158	53	1
13	1	189	60.0	23.0	846.0	30.1	0.398	59	1
14	5	166	72.0	19.0	175.0	25.8	0.587	51	1
16	0	118	84.0	47.0	230.0	45.8	0.551	31	1
18	1	103	30.0	38.0	83.0	43.3	0.183	33	0
19	1	115	70.0	30.0	96.0	34.6	0.529	32	1

	emb	gl2h	pad	ept	is2h	imc	fpd	edad	class
0	6	148	72.0	35.0	NaN	33.6	0.627	50	1
1	1	85	66.0	29.0	NaN	26.6	0.351	31	0
2	8	183	64.0	NaN	NaN	23.3	0.672	32	1
3	1	89	66.0	23.0	94.0	28.1	0.167	21	0
4	0	137	40.0	35.0	168.0	43.1	2.288	33	1
5	5	116	74.0	NaN	NaN	25.6	0.201	30	0
6	3	78	50.0	32.0	88.0	31.0	0.248	26	1
8	2	197	70.0	45.0	543.0	30.5	0.158	53	1
10	4	110	92.0	NaN	NaN	37.6	0.191	30	0
11	10	168	74.0	NaN	NaN	38.0	0.537	34	1
12	10	139	80.0	NaN	NaN	27.1	1.441	57	0
13	1	189	60.0	23.0	846.0	30.1	0.398	59	1
14	5	166	72.0	19.0	175.0	25.8	0.587	51	1
16	0	118	84.0	47.0	230.0	45.8	0.551	31	1
17	7	107	74.0	NaN	NaN	29.6	0.254	31	1
18	1	103	30.0	38.0	83.0	43.3	0.183	33	0
19	1	115	70.0	30.0	96.0	34.6	0.529	32	1

Imputación

El análisis de casos completos es una opción aceptable si el porcentaje de valores faltantes es pequeño. En la mayoría de los casos, es preferible reemplazar los valores faltantes por valores calculados por omisión o valores calculados. Esta operación se denomina **imputación**. En el siguiente ejemplo, todos los valores *NaN* son reemplazados por 0, lo cual pudiera seguir la lógica de que "si el dato no está disponible es que en realidad era cero.

In [9]:
```
print(df, "\n")
df3 = df.fillna(0)
print(df3, "\n")
print (df3.describe())
```

	emb	gl2h	pad	ept	is2h	imc	fpd	edad	class
0	6	148	72.0	35.0	NaN	33.6	0.627	50	1
1	1	85	66.0	29.0	NaN	26.6	0.351	31	0
2	8	183	64.0	NaN	NaN	23.3	0.672	32	1
3	1	89	66.0	23.0	94.0	28.1	0.167	21	0
4	0	137	40.0	35.0	168.0	43.1	2.288	33	1
5	5	116	74.0	NaN	NaN	25.6	0.201	30	0
6	3	78	50.0	32.0	88.0	31.0	0.248	26	1
7	10	115	NaN	NaN	NaN	35.3	0.134	29	0
8	2	197	70.0	45.0	543.0	30.5	0.158	53	1
9	8	125	96.0	NaN	NaN	NaN	0.232	54	1
10	4	110	92.0	NaN	NaN	37.6	0.191	30	0
11	10	168	74.0	NaN	NaN	38.0	0.537	34	1
12	10	139	80.0	NaN	NaN	27.1	1.441	57	0
13	1	189	60.0	23.0	846.0	30.1	0.398	59	1
14	5	166	72.0	19.0	175.0	25.8	0.587	51	1
15	7	100	NaN	NaN	NaN	30.0	0.484	32	1
16	0	118	84.0	47.0	230.0	45.8	0.551	31	1
17	7	107	74.0	NaN	NaN	29.6	0.254	31	1
18	1	103	30.0	38.0	83.0	43.3	0.183	33	0
19	1	115	70.0	30.0	96.0	34.6	0.529	32	1

```
    emb  gl2h   pad   ept    is2h   imc    fpd  edad  class
0     6   148  72.0  35.0     0.0  33.6  0.627    50      1
1     1    85  66.0  29.0     0.0  26.6  0.351    31      0
2     8   183  64.0   0.0     0.0  23.3  0.672    32      1
3     1    89  66.0  23.0    94.0  28.1  0.167    21      0
4     0   137  40.0  35.0   168.0  43.1  2.288    33      1
5     5   116  74.0   0.0     0.0  25.6  0.201    30      0
6     3    78  50.0  32.0    88.0  31.0  0.248    26      1
7    10   115   0.0   0.0     0.0  35.3  0.134    29      0
8     2   197  70.0  45.0   543.0  30.5  0.158    53      1
9     8   125  96.0   0.0     0.0   0.0  0.232    54      1
10    4   110  92.0   0.0     0.0  37.6  0.191    30      0
11   10   168  74.0   0.0     0.0  38.0  0.537    34      1
12   10   139  80.0   0.0     0.0  27.1  1.441    57      0
13    1   189  60.0  23.0   846.0  30.1  0.398    59      1
14    5   166  72.0  19.0   175.0  25.8  0.587    51      1
15    7   100   0.0   0.0     0.0  30.0  0.484    32      1
16    0   118  84.0  47.0   230.0  45.8  0.551    31      1
17    7   107  74.0   0.0     0.0  29.6  0.254    31      1
18    1   103  30.0  38.0    83.0  43.3  0.183    33      0
19    1   115  70.0  30.0    96.0  34.6  0.529    32      1

             emb        gl2h        pad        ept         is2h        imc  \
count  20.00000   20.000000  20.000000  20.000000   20.000000  20.000000
mean    4.50000  129.400000  61.700000  17.800000  116.150000  30.950000
std     3.56149   35.354446  26.159631  17.733703  215.843821   9.654424
min     0.00000   78.000000   0.000000   0.000000    0.000000   0.000000
25%     1.00000  106.000000  57.500000   0.000000    0.000000  26.975000
50%     4.50000  117.000000  70.000000  21.000000    0.000000  30.300000
75%     7.25000  152.500000  74.000000  32.750000  114.000000  35.875000
max    10.00000  197.000000  96.000000  47.000000  846.000000  45.800000

             fpd       edad     class
count  20.000000  20.000000  20.00000
mean    0.511650  37.450000   0.65000
std     0.513691  11.591626   0.48936
min     0.134000  21.000000   0.00000
25%     0.198500  30.750000   0.00000
50%     0.374500  32.000000   1.00000
75%     0.560000  50.250000   1.00000
max     2.288000  59.000000   1.00000
```

Sin embargo, en muchos casos un valor por omisión de cero no tiene sentido. En nuestro ejemplo con los datos de diabetes, un valor de cero en la columna *pad* (*Presión diastólica de la sangre*) es imposible en una persona viva. En este caso, una mejor opción es rellenar los valores faltantes por el mínimo registrado:

In [10]:
```
df3 = df.fillna(df.min())
print(df3, "\n")
print (df3.describe())
```

	emb	gl2h	pad	ept	is2h	imc	fpd	edad	class
0	6	148	72.0	35.0	83.0	33.6	0.627	50	1
1	1	85	66.0	29.0	83.0	26.6	0.351	31	0
2	8	183	64.0	19.0	83.0	23.3	0.672	32	1
3	1	89	66.0	23.0	94.0	28.1	0.167	21	0
4	0	137	40.0	35.0	168.0	43.1	2.288	33	1
5	5	116	74.0	19.0	83.0	25.6	0.201	30	0
6	3	78	50.0	32.0	88.0	31.0	0.248	26	1
7	10	115	30.0	19.0	83.0	35.3	0.134	29	0
8	2	197	70.0	45.0	543.0	30.5	0.158	53	1
9	8	125	96.0	19.0	83.0	23.3	0.232	54	1
10	4	110	92.0	19.0	83.0	37.6	0.191	30	0
11	10	168	74.0	19.0	83.0	38.0	0.537	34	1
12	10	139	80.0	19.0	83.0	27.1	1.441	57	0
13	1	189	60.0	23.0	846.0	30.1	0.398	59	1
14	5	166	72.0	19.0	175.0	25.8	0.587	51	1
15	7	100	30.0	19.0	83.0	30.0	0.484	32	1
16	0	118	84.0	47.0	230.0	45.8	0.551	31	1
17	7	107	74.0	19.0	83.0	29.6	0.254	31	1
18	1	103	30.0	38.0	83.0	43.3	0.183	33	0
19	1	115	70.0	30.0	96.0	34.6	0.529	32	1

	emb	gl2h	pad	ept	is2h	imc	\
count	20.00000	20.000000	20.000000	20.000000	20.000000	20.000000	
mean	4.50000	129.400000	64.700000	26.350000	161.800000	32.115000	
std	3.56149	35.354446	19.491159	9.387982	192.926656	6.666592	
min	0.00000	78.000000	30.000000	19.000000	83.000000	23.300000	
25%	1.00000	106.000000	57.500000	19.000000	83.000000	26.975000	
50%	4.50000	117.000000	70.000000	21.000000	83.000000	30.300000	
75%	7.25000	152.500000	74.000000	32.750000	114.000000	35.875000	
max	10.00000	197.000000	96.000000	47.000000	846.000000	45.800000	

	fpd	edad	class
count	20.000000	20.000000	20.00000
mean	0.511650	37.450000	0.65000
std	0.513691	11.591626	0.48936
min	0.134000	21.000000	0.00000
25%	0.198500	30.750000	0.00000
50%	0.374500	32.000000	1.00000
75%	0.560000	50.250000	1.00000
max	2.288000	59.000000	1.00000

Otras alternativas comunes son rellenar los valores faltantes con el valor máximo o con valores estadísticos.

Reemplazar los valores faltantes por el valor promedio de esa variable es uno de los métodos más comunes de imputación, sin embargo, la media es una medida vulnerable a valores atípicos. Una alternativa más robusta ante este problema es la mediana.

In [11]:
```
print("Rellenando con el valor máximo \n", df.fillna(df.max()).describe(), "\n")
print("Rellenando con la media \n", df.fillna(df.mean()).describe(), "\n")
print("Rellenando con la mediana \n", df.fillna(df.median()).describe(), "\n")
print("Rellenando con la moda \n", df.fillna(df.mode()).describe())
```

```
Rellenando con el valor máximo
```

	emb	gl2h	pad	ept	is2h	imc	\
count	20.00000	20.000000	20.000000	20.000000	20.000000	20.000000	
mean	4.50000	129.400000	71.300000	38.950000	581.450000	33.240000	
std	3.56149	35.354446	17.619069	9.870077	345.359687	6.991303	
min	0.00000	78.000000	30.000000	19.000000	83.000000	23.300000	
25%	1.00000	106.000000	65.500000	31.500000	173.250000	27.850000	
50%	4.50000	117.000000	72.000000	46.000000	846.000000	30.750000	
75%	7.25000	152.500000	81.000000	47.000000	846.000000	37.700000	
max	10.00000	197.000000	96.000000	47.000000	846.000000	45.800000	

```
             fpd       edad     class
count  20.000000  20.000000  20.00000
mean    0.511650  37.450000   0.65000
std     0.513691  11.591626   0.48936
min     0.134000  21.000000   0.00000
25%     0.198500  30.750000   0.00000
50%     0.374500  32.000000   1.00000
75%     0.560000  50.250000   1.00000
max     2.288000  59.000000   1.00000

Rellenando con la media
             emb        gl2h        pad        ept        is2h        imc  \
count  20.00000   20.000000  20.000000  20.000000   20.000000  20.000000
mean    4.50000  129.400000  68.555556  32.363636  258.111111  32.578947
std     3.56149   35.354446  15.462083   6.450400  170.973511   6.335496
min     0.00000   78.000000  30.000000  19.000000   83.000000  23.300000
25%     1.00000  106.000000  65.500000  31.500000  173.250000  27.850000
50%     4.50000  117.000000  70.000000  32.363636  258.111111  30.750000
75%     7.25000  152.500000  74.000000  33.022727  258.111111  35.875000
max    10.00000  197.000000  96.000000  47.000000  846.000000  45.800000

             fpd       edad     class
count  20.000000  20.000000  20.00000
mean    0.511650  37.450000   0.65000
std     0.513691  11.591626   0.48936
min     0.134000  21.000000   0.00000
25%     0.198500  30.750000   0.00000
50%     0.374500  32.000000   1.00000
75%     0.560000  50.250000   1.00000
max     2.288000  59.000000   1.00000

Rellenando con la mediana
             emb        gl2h        pad        ept        is2h        imc  \
count  20.00000   20.000000  20.000000  20.000000   20.000000  20.000000
mean    4.50000  129.400000  68.800000  32.200000  208.550000  32.475000
std     3.56149   35.354446  15.480378   6.453069  177.052022   6.352527
min     0.00000   78.000000  30.000000  19.000000   83.000000  23.300000
25%     1.00000  106.000000  65.500000  31.500000  168.000000  27.850000
50%     4.50000  117.000000  71.000000  32.000000  168.000000  30.500000
75%     7.25000  152.500000  74.000000  32.750000  168.000000  35.875000
max    10.00000  197.000000  96.000000  47.000000  846.000000  45.800000

             fpd       edad     class
count  20.000000  20.000000  20.00000
mean    0.511650  37.450000   0.65000
std     0.513691  11.591626   0.48936
min     0.134000  21.000000   0.00000
25%     0.198500  30.750000   0.00000
50%     0.374500  32.000000   1.00000
75%     0.560000  50.250000   1.00000
max     2.288000  59.000000   1.00000

Rellenando con la moda
             emb        gl2h        pad        ept        is2h        imc  \
count  20.00000   20.000000  18.000000  11.000000   14.000000  20.000000
mean    4.50000  129.400000  68.555556  32.363636  236.142857  32.475000
std     3.56149   35.354446  16.346333   8.891262  235.870518   6.352527
min     0.00000   78.000000  30.000000  19.000000   83.000000  23.300000
25%     1.00000  106.000000  64.500000  26.000000   89.500000  27.850000
50%     4.50000  117.000000  71.000000  32.000000  132.000000  30.500000
75%     7.25000  152.500000  74.000000  36.500000  216.250000  35.875000
max    10.00000  197.000000  96.000000  47.000000  846.000000  45.800000
```

```
             fpd       edad     class
count  20.000000  20.000000  20.00000
mean    0.511650  37.450000   0.65000
std     0.513691  11.591626   0.48936
min     0.134000  21.000000   0.00000
25%     0.198500  30.750000   0.00000
50%     0.374500  32.000000   1.00000
75%     0.560000  50.250000   1.00000
max     2.288000  59.000000   1.00000
```

Otra alternativa común es rellenar los valores faltantes con el valor no nulo previo o el siguiente:

In [12]:
```
print(df, "\n")
print("Replicar hacia enfrente\n", df.fillna(method='pad'), "\n")
print("Replicar hacia atrás\n", df.fillna(method='bfill'))
```

```
    emb  gl2h   pad   ept   is2h   imc    fpd  edad  class
0     6   148  72.0  35.0    NaN  33.6  0.627    50      1
1     1    85  66.0  29.0    NaN  26.6  0.351    31      0
2     8   183  64.0   NaN    NaN  23.3  0.672    32      1
3     1    89  66.0  23.0   94.0  28.1  0.167    21      0
4     0   137  40.0  35.0  168.0  43.1  2.288    33      1
5     5   116  74.0   NaN    NaN  25.6  0.201    30      0
6     3    78  50.0  32.0   88.0  31.0  0.248    26      1
7    10   115   NaN   NaN    NaN  35.3  0.134    29      0
8     2   197  70.0  45.0  543.0  30.5  0.158    53      1
9     8   125  96.0   NaN    NaN   NaN  0.232    54      1
10    4   110  92.0   NaN    NaN  37.6  0.191    30      0
11   10   168  74.0   NaN    NaN  38.0  0.537    34      1
12   10   139  80.0   NaN    NaN  27.1  1.441    57      0
13    1   189  60.0  23.0  846.0  30.1  0.398    59      1
14    5   166  72.0  19.0  175.0  25.8  0.587    51      1
15    7   100   NaN   NaN    NaN  30.0  0.484    32      1
16    0   118  84.0  47.0  230.0  45.8  0.551    31      1
17    7   107  74.0   NaN    NaN  29.6  0.254    31      1
18    1   103  30.0  38.0   83.0  43.3  0.183    33      0
19    1   115  70.0  30.0   96.0  34.6  0.529    32      1

Replicar hacia enfrente
     emb  gl2h   pad   ept   is2h   imc    fpd  edad  class
0     6   148  72.0  35.0    NaN  33.6  0.627    50      1
1     1    85  66.0  29.0    NaN  26.6  0.351    31      0
2     8   183  64.0  29.0    NaN  23.3  0.672    32      1
3     1    89  66.0  23.0   94.0  28.1  0.167    21      0
4     0   137  40.0  35.0  168.0  43.1  2.288    33      1
5     5   116  74.0  35.0  168.0  25.6  0.201    30      0
6     3    78  50.0  32.0   88.0  31.0  0.248    26      1
7    10   115  50.0  32.0   88.0  35.3  0.134    29      0
8     2   197  70.0  45.0  543.0  30.5  0.158    53      1
9     8   125  96.0  45.0  543.0  30.5  0.232    54      1
10    4   110  92.0  45.0  543.0  37.6  0.191    30      0
11   10   168  74.0  45.0  543.0  38.0  0.537    34      1
12   10   139  80.0  45.0  543.0  27.1  1.441    57      0
13    1   189  60.0  23.0  846.0  30.1  0.398    59      1
14    5   166  72.0  19.0  175.0  25.8  0.587    51      1
15    7   100  72.0  19.0  175.0  30.0  0.484    32      1
16    0   118  84.0  47.0  230.0  45.8  0.551    31      1
17    7   107  74.0  47.0  230.0  29.6  0.254    31      1
18    1   103  30.0  38.0   83.0  43.3  0.183    33      0
19    1   115  70.0  30.0   96.0  34.6  0.529    32      1
```

```
Replicar hacia atrás
     emb  gl2h   pad   ept   is2h   imc    fpd  edad  class
0      6   148  72.0  35.0   94.0  33.6  0.627    50      1
1      1    85  66.0  29.0   94.0  26.6  0.351    31      0
2      8   183  64.0  23.0   94.0  23.3  0.672    32      1
3      1    89  66.0  23.0   94.0  28.1  0.167    21      0
4      0   137  40.0  35.0  168.0  43.1  2.288    33      1
5      5   116  74.0  32.0   88.0  25.6  0.201    30      0
6      3    78  50.0  32.0   88.0  31.0  0.248    26      1
7     10   115  70.0  45.0  543.0  35.3  0.134    29      0
8      2   197  70.0  45.0  543.0  30.5  0.158    53      1
9      8   125  96.0  23.0  846.0  37.6  0.232    54      1
10     4   110  92.0  23.0  846.0  37.6  0.191    30      0
11    10   168  74.0  23.0  846.0  38.0  0.537    34      1
12    10   139  80.0  23.0  846.0  27.1  1.441    57      0
13     1   189  60.0  23.0  846.0  30.1  0.398    59      1
14     5   166  72.0  19.0  175.0  25.8  0.587    51      1
15     7   100  84.0  47.0  230.0  30.0  0.484    32      1
16     0   118  84.0  47.0  230.0  45.8  0.551    31      1
17     7   107  74.0  38.0   83.0  29.6  0.254    31      1
18     1   103  30.0  38.0   83.0  43.3  0.183    33      0
19     1   115  70.0  30.0   96.0  34.6  0.529    32      1
```

Esta forma de tratar el problema de valores faltantes es muy común en análisis de series de tiempo. Esta estrategia suele designarse como *último valor conocido* y equivale a asumir que el sistema no pudo cambiar demasiado desde la última medición. En otros casos debe analizarse si los datos realmente tienen una estructura local; esto es, determinar si tiene sentido esperar que los registros vecinos tengan valores cercanos. en el caso del conjunto de datos de diabetes, esta suposición no es válida.

Podemos también limitar el número de registros que son modificados de esta forma:

In [13]:
```
print(df.fillna(method='pad', limit=1))
```

```
    emb  gl2h   pad   ept   is2h   imc    fpd  edad  class
0     6   148  72.0  35.0    NaN  33.6  0.627    50      1
1     1    85  66.0  29.0    NaN  26.6  0.351    31      0
2     8   183  64.0  29.0    NaN  23.3  0.672    32      1
3     1    89  66.0  23.0   94.0  28.1  0.167    21      0
4     0   137  40.0  35.0  168.0  43.1  2.288    33      1
5     5   116  74.0  35.0  168.0  25.6  0.201    30      0
6     3    78  50.0  32.0   88.0  31.0  0.248    26      1
7    10   115  50.0  32.0   88.0  35.3  0.134    29      0
8     2   197  70.0  45.0  543.0  30.5  0.158    53      1
9     8   125  96.0  45.0  543.0  30.5  0.232    54      1
10    4   110  92.0   NaN    NaN  37.6  0.191    30      0
11   10   168  74.0   NaN    NaN  38.0  0.537    34      1
12   10   139  80.0   NaN    NaN  27.1  1.441    57      0
13    1   189  60.0  23.0  846.0  30.1  0.398    59      1
14    5   166  72.0  19.0  175.0  25.8  0.587    51      1
15    7   100  72.0  19.0  175.0  30.0  0.484    32      1
16    0   118  84.0  47.0  230.0  45.8  0.551    31      1
17    7   107  74.0  47.0  230.0  29.6  0.254    31      1
18    1   103  30.0  38.0   83.0  43.3  0.183    33      0
19    1   115  70.0  30.0   96.0  34.6  0.529    32      1
```

Interpolación

La interpolación es un método formal para estimar valores en una serie de datos. La idea consiste en suponer que todos los puntos en la serie se encuentran sobre una curva subyacente, aunque desconocida. La forma más simple de interpolación es la *lineal*. En este caso se parte de dos puntos conocidos y los puntos intermedios (faltantes) se calculan como si estuvieran colocados sobre la línea recta que une a los puntos conocidos.

In [14]:
```
%matplotlib inline

import matplotlib
import matplotlib.pyplot as plt
```

In [15]:
```
fig, axes = plt.subplots(nrows=2, ncols=1, sharex=True, sharey=True, figsize=(10,10))
df['ept'].plot(ax=axes[0])
df['ept'].plot(ax=axes[0], grid=True, kind="bar")

dfi = df['ept'].interpolate()
dfi.plot(ax=axes[1])
dfi.plot(ax=axes[1], grid=True, kind="bar", color="red")
df['ept'].plot(ax=axes[1], grid=True, kind="bar")

print (df['ept'].interpolate())
```

```
0     35.0
1     29.0
2     26.0
3     23.0
4     35.0
5     33.5
6     32.0
7     38.5
8     45.0
9     40.6
10    36.2
11    31.8
12    27.4
13    23.0
14    19.0
15    33.0
16    47.0
17    42.5
18    38.0
19    30.0
Name: ept, dtype: float64
```

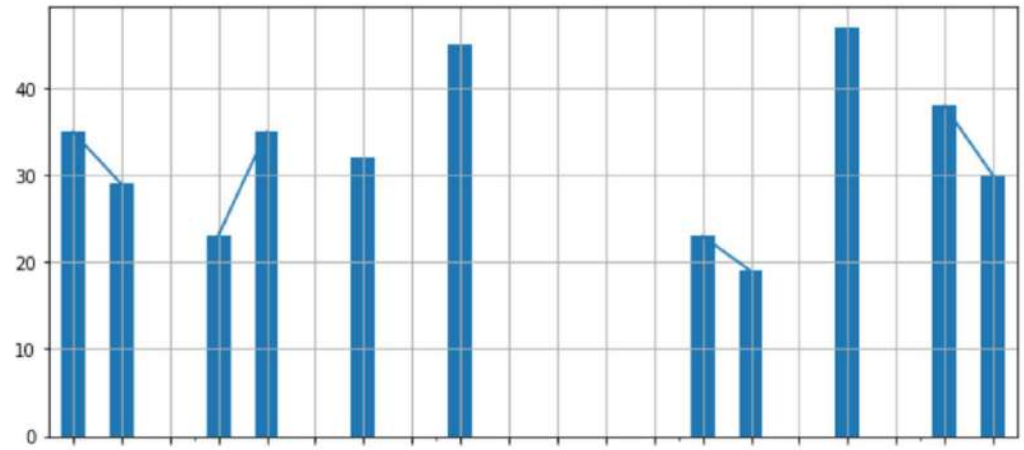

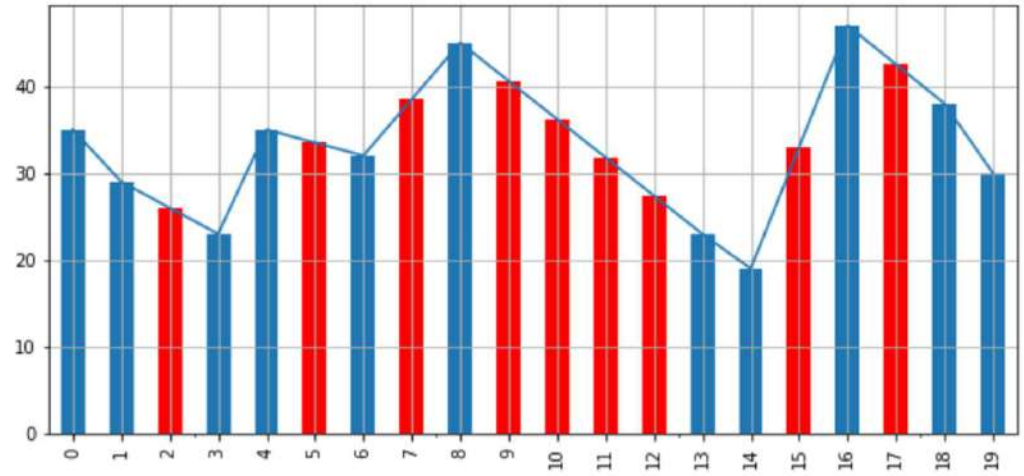

La aproximación lineal, aunque es la más simple, es la menos natural. Es posible utilizar cualquier otro conjunto de curvas, típicamente de la forma, que se ajusten a los datos conocidos. A continuación, se presentan ajustes a curvas cuadráticas y cúbicas:

In [16]:
```
fig, axes = plt.subplots(nrows=2, ncols=1, sharex=True, sharey=True, figsize=(10,10))
dfi = df['ept'].interpolate(method="quadratic")
dfi.plot(ax=axes[0])
dfi.plot(ax=axes[0], grid=True, kind="bar", color="red")
df['ept'].plot(ax=axes[0], grid=True, kind="bar")

dfi = df['ept'].interpolate(method="cubic")
dfi.plot(ax=axes[1])
dfi.plot(ax=axes[1], grid=True, kind="bar", color="red")
df['ept'].plot(ax=axes[1], grid=True, kind="bar")
```

Out[16]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x11b169358>
```

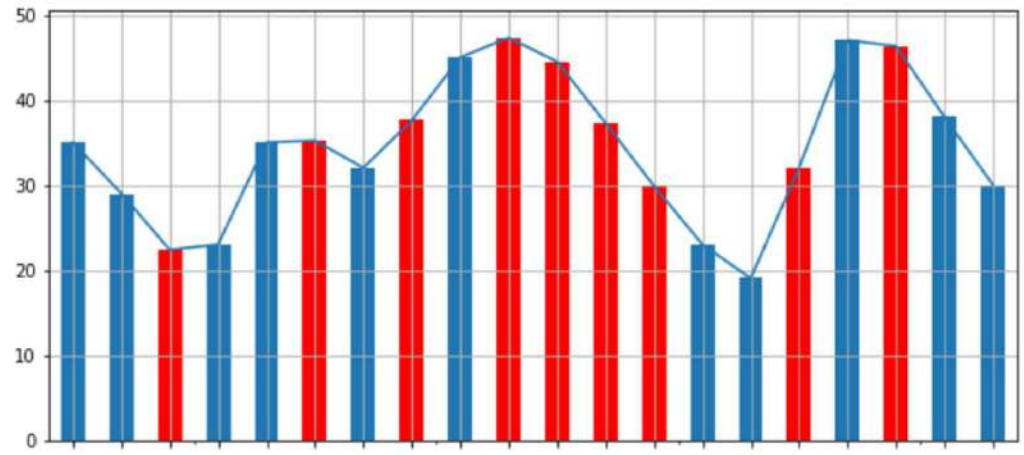

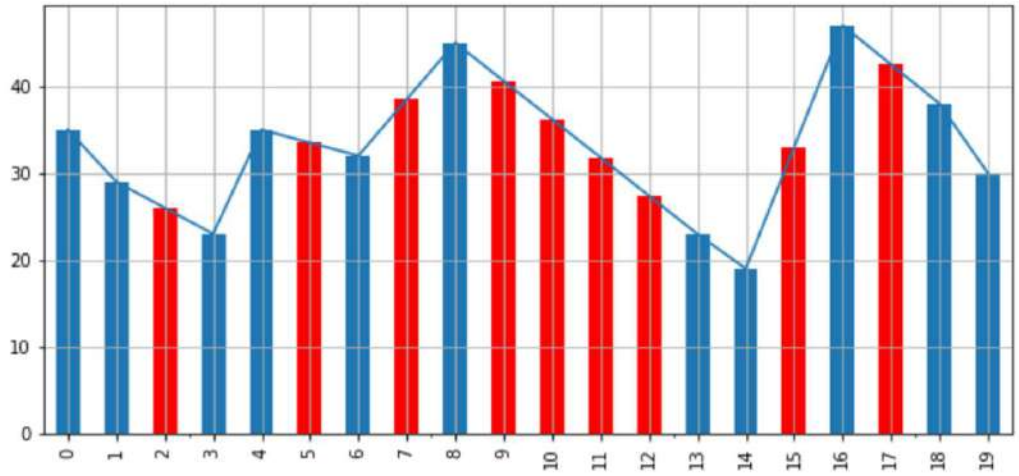

La aproximación lineal, aunque es la más simple, es la menos natural. Es posible utilizar cualquier otro conjunto de curvas, típicamente de la forma, que se ajusten a los datos conocidos. A continuación, se presentan ajustes a curvas cuadráticas y cúbicas:

In [16]:
```
fig, axes = plt.subplots(nrows=2, ncols=1, sharex=True, sharey=True, figsize=(10,10))
dfi = df['ept'].interpolate(method="quadratic")
dfi.plot(ax=axes[0])
dfi.plot(ax=axes[0], grid=True, kind="bar", color="red")
df['ept'].plot(ax=axes[0], grid=True, kind="bar")

dfi = df['ept'].interpolate(method="cubic")
dfi.plot(ax=axes[1])
dfi.plot(ax=axes[1], grid=True, kind="bar", color="red")
df['ept'].plot(ax=axes[1], grid=True, kind="bar")
```

Out[16]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x11b169358>
```

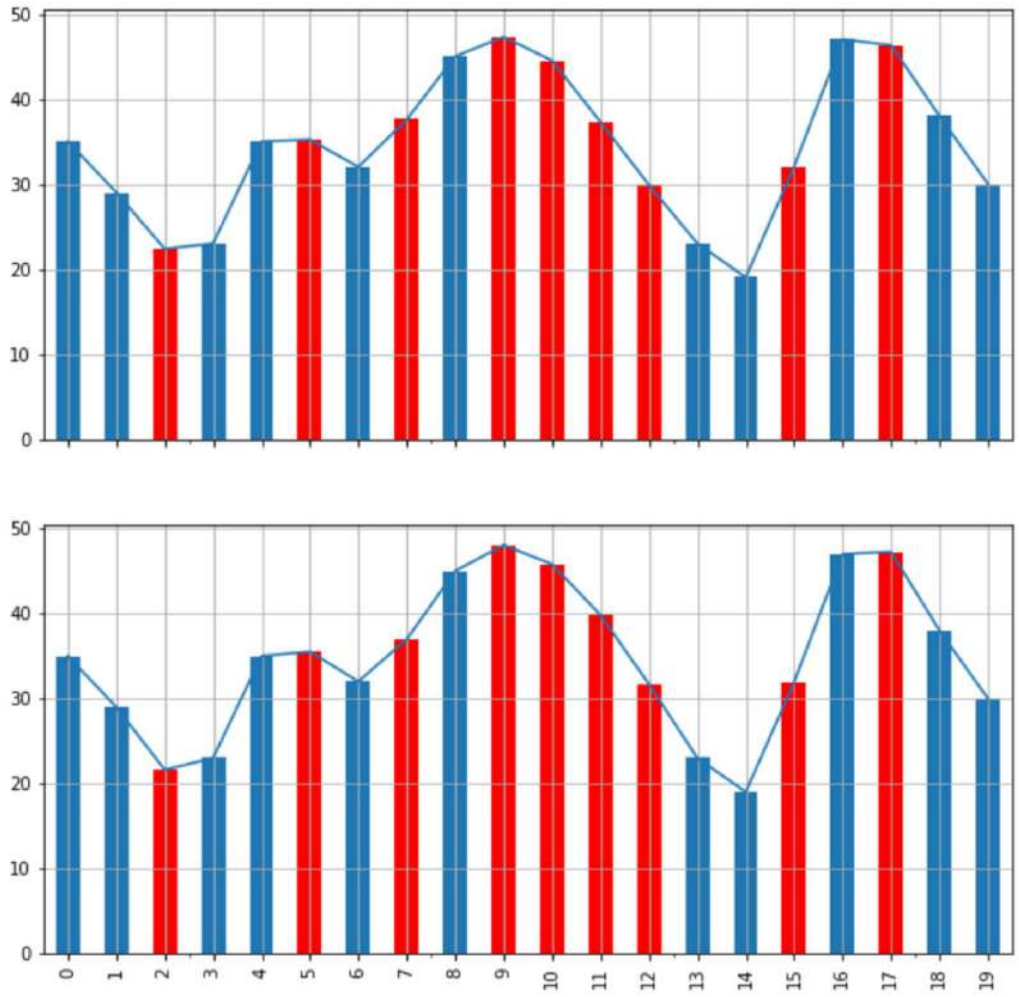

Cualquier otra técnica de predicción puede ser empleada para rellenar los valores faltantes. Una de las más importantes es el razonamiento basado en casos (RBC).

Valores atípicos

Un valor atípico es una observación que se ubica fuera del patrón general de distribución de los datos (Mathworld).

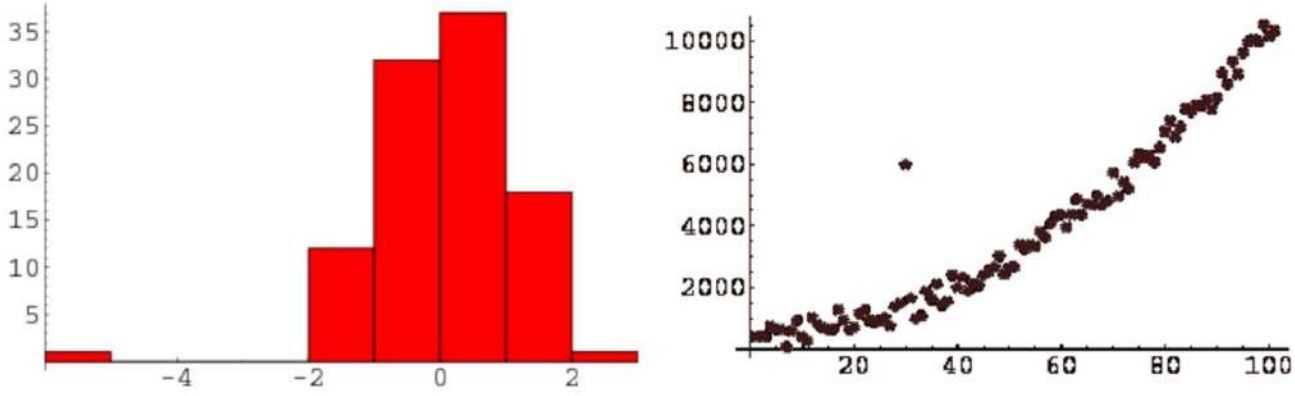

Los valores atípicos pueden deberse a diferentes causas, siendo las principales:

- Casos que no se ajustan al modelo de estudio
- Errores en la medición

El tratamiento dado a los valores atípicos depende del origen de la inconsistencia. En el caso de errores en la medición pueden eliminarse o ajustarse (como en el caso de valores faltantes). Cuando la causa es que los casos no se ajustan al modelo utilizado pueden indicar la necesidad de replantear el modelo (incluyendo modificaciones a la teoría, como sucedía con el caso del movimiento anómalo de Mercurio). Sin embargo, también pueden representar casos singulares o excepcionales. En cualquier caso, es importante detectar estos valores, pues su presencia generan tendencias en el análisis global de los datos.

Una forma común de analizar la presencia de valores atípicos es a través de los diagramas de caja (boxplots). El diagrama de caja es una descripción gráfica de la agrupación de los datos en base a sus cuartiles y tiene la siguiente estructura:

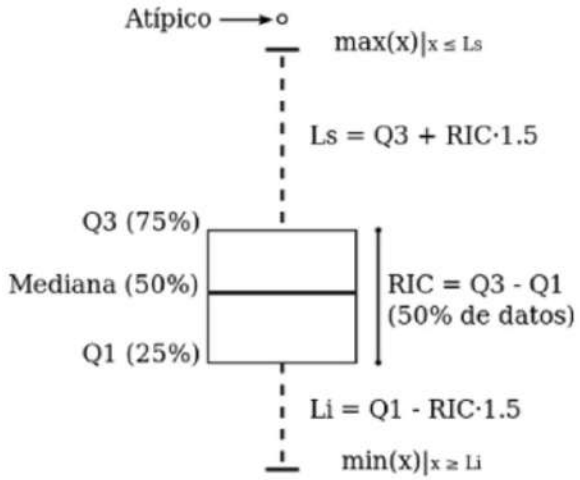

El espaciado entre los componentes de una caja reflejan la dispersión y tendencias en los datos. La parte principal de esta representación es la propia caja. La tapa inferior corresponde al primer cuartil (Q1, el punto que separa el 25% de los datos inferiores), la línea intermedia refleja la mediana o segundo cuartil (Q2) y la tapa superior corresponde al tercer cuartil (Q3, el punto que delimita el 75% de los datos inferiores). RIC es el *rango inter cuartil* y es el 50% de los datos que quedan al centro del conjunto total de datos. Las líneas punteadas se denomina *bigotes* (*whiskers*); los extremos de los bigotes inferior y superior suelen seleccionarse como el menor dato que aún queda a una distancia máxima de 1.5 veces RIC por abajo de Q1 y el dato máximo a una distancia igual o menor de 1.5 RIC por arriba de Q3.

Analizamos la submuestra de datos de diabetes, en primera instancia para la variable '*gl2h*' y posteriormente para todo el conjunto, utilizando los datos con valores faltantes en cero.

In [17]:
```
%matplotlib inline

#import warnings
#warnings.filterwarnings("ignore")
```

In [18]:
```
df2 = pd.read_csv(path + "pima-indians-diabetes.data-small-orig",
                  names = ['emb', 'gl2h', 'pad', 'ept', 'is2h', 'imc', 'fpd', 'edad', 'class'])

print(df2)
print(df2.describe())
df2.boxplot(column='gl2h')
plt.show()
```

```
    emb  gl2h  pad  ept  is2h   imc    fpd  edad  class
0     6   148   72   35     0  33.6  0.627    50      1
1     1    85   66   29     0  26.6  0.351    31      0
2     8   183   64    0     0  23.3  0.672    32      1
3     1    89   66   23    94  28.1  0.167    21      0
4     0   137   40   35   168  43.1  2.288    33      1
5     5   116   74    0     0  25.6  0.201    30      0
6     3    78   50   32    88  31.0  0.248    26      1
7    10   115    0    0     0  35.3  0.134    29      0
8     2   197   70   45   543  30.5  0.158    53      1
9     8   125   96    0     0   0.0  0.232    54      1
10    4   110   92    0     0  37.6  0.191    30      0
11   10   168   74    0     0  38.0  0.537    34      1
12   10   139   80    0     0  27.1  1.441    57      0
13    1   189   60   23   846  30.1  0.398    59      1
14    5   166   72   19   175  25.8  0.587    51      1
15    7   100    0    0     0  30.0  0.484    32      1
16    0   118   84   47   230  45.8  0.551    31      1
17    7   107   74    0     0  29.6  0.254    31      1
18    1   103   30   38    83  43.3  0.183    33      0
19    1   115   70   30    96  34.6  0.529    32      1
             emb        gl2h        pad        ept        is2h        imc  \
count  20.00000   20.000000  20.000000  20.000000   20.000000  20.000000
mean    4.50000  129.400000  61.700000  17.800000  116.150000  30.950000
std     3.56149   35.354446  26.159631  17.733703  215.843821   9.654424
min     0.00000   78.000000   0.000000   0.000000    0.000000   0.000000
25%     1.00000  106.000000  57.500000   0.000000    0.000000  26.975000
50%     4.50000  117.000000  70.000000  21.000000    0.000000  30.300000
75%     7.25000  152.500000  74.000000  32.750000  114.000000  35.875000
max    10.00000  197.000000  96.000000  47.000000  846.000000  45.800000

             fpd       edad     class
count  20.000000  20.000000  20.00000
mean    0.511650  37.450000   0.65000
std     0.513691  11.591626   0.48936
min     0.134000  21.000000   0.00000
25%     0.198500  30.750000   0.00000
50%     0.374500  32.000000   1.00000
75%     0.560000  50.250000   1.00000
max     2.288000  59.000000   1.00000
```

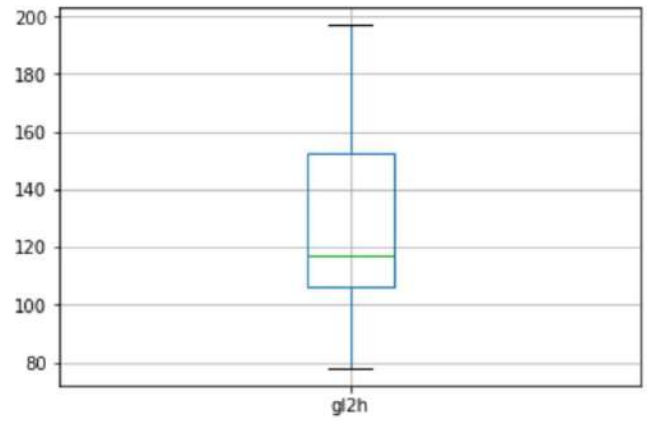

In [19]:
```
df.boxplot()
plt.show()
```

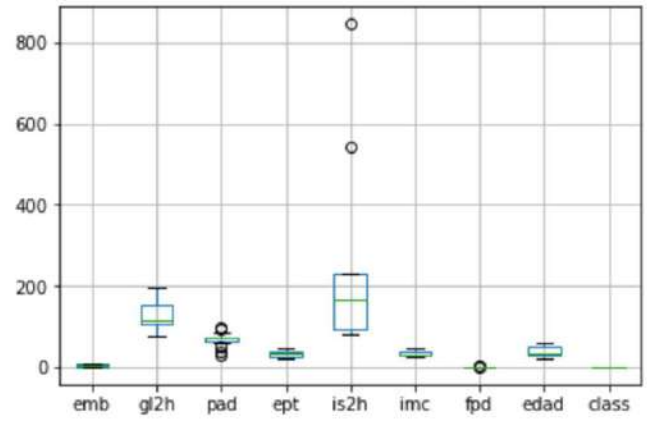

Obsérvese que los datos en cero ejercen un efecto importante en el análisis. En el caso de la columna *is2h*, por ejemplo, con 11 valores faltantes puestos a cero, pareciera que ese es un valor *típico*. En estos casos es importante realizar previamente el análisis para detectar valores faltantes expresados como 0. A continuación, realizamos el análisis con los datos después de hacer una imputación con la media.

In [20]:
```
df2 = df.fillna(df.mean())
print(df2.describe(), '\n')
print(df2)

df2.boxplot()
plt.show()
```

```
             emb        gl2h        pad        ept        is2h        imc  \
count  20.00000   20.000000  20.000000  20.000000   20.000000  20.000000
mean    4.50000  129.400000  68.555556  32.363636  258.111111  32.578947
std     3.56149   35.354446  15.462083   6.450400  170.973511   6.335496
min     0.00000   78.000000  30.000000  19.000000   83.000000  23.300000
25%     1.00000  106.000000  65.500000  31.500000  173.250000  27.850000
50%     4.50000  117.000000  70.000000  32.363636  258.111111  30.750000
75%     7.25000  152.500000  74.000000  33.022727  258.111111  35.875000
max    10.00000  197.000000  96.000000  47.000000  846.000000  45.800000

             fpd       edad     class
count  20.000000  20.000000  20.00000
mean    0.511650  37.450000   0.65000
std     0.513691  11.591626   0.48936
min     0.134000  21.000000   0.00000
25%     0.198500  30.750000   0.00000
50%     0.374500  32.000000   1.00000
75%     0.560000  50.250000   1.00000
max     2.288000  59.000000   1.00000
```

	emb	gl2h	pad	ept	is2h	imc	fpd	edad	class
0	6	148	72.000000	35.000000	258.111111	33.600000	0.627	50	1
1	1	85	66.000000	29.000000	258.111111	26.600000	0.351	31	0
2	8	183	64.000000	32.363636	258.111111	23.300000	0.672	32	1
3	1	89	66.000000	23.000000	94.000000	28.100000	0.167	21	0
4	0	137	40.000000	35.000000	168.000000	43.100000	2.288	33	1
5	5	116	74.000000	32.363636	258.111111	25.600000	0.201	30	0
6	3	78	50.000000	32.000000	88.000000	31.000000	0.248	26	1
7	10	115	68.555556	32.363636	258.111111	35.300000	0.134	29	0
8	2	197	70.000000	45.000000	543.000000	30.500000	0.158	53	1
9	8	125	96.000000	32.363636	258.111111	32.578947	0.232	54	1
10	4	110	92.000000	32.363636	258.111111	37.600000	0.191	30	0
11	10	168	74.000000	32.363636	258.111111	38.000000	0.537	34	1
12	10	139	80.000000	32.363636	258.111111	27.100000	1.441	57	0
13	1	189	60.000000	23.000000	846.000000	30.100000	0.398	59	1
14	5	166	72.000000	19.000000	175.000000	25.800000	0.587	51	1
15	7	100	68.555556	32.363636	258.111111	30.000000	0.484	32	1
16	0	118	84.000000	47.000000	230.000000	45.800000	0.551	31	1
17	7	107	74.000000	32.363636	258.111111	29.600000	0.254	31	1
18	1	103	30.000000	38.000000	83.000000	43.300000	0.183	33	0
19	1	115	70.000000	30.000000	96.000000	34.600000	0.529	32	1

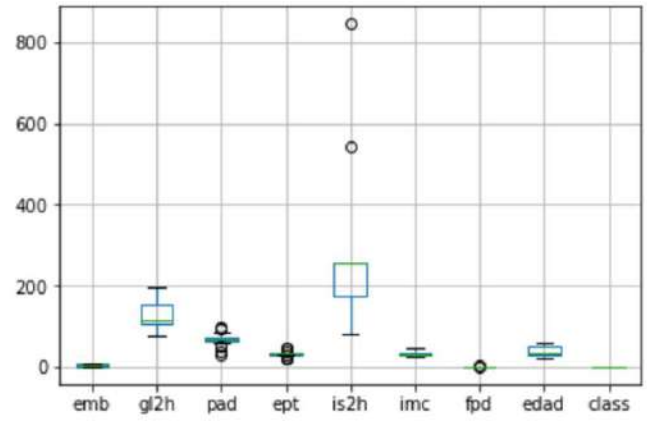

Obsérvese que la columna *is2h* (Cantidad de insulina en suero en dos horas) sigue teniendo un comportamiento problemático. Aparentemente, hasta donde podemos *adivinar* de los datos, 543 y 846 son valores atípicos. Sin embargo, con 11 valores faltantes (55%) es poco lo que se puede decir con certeza del comportamiento de estos datos.

Valores inconsistentes

Una inconsistencia se define como la "falta de estabilidad y coherencia en una cosa". Un elemento inconsistente en un sistema es algo que no pertenece al sistema. Un valor inconsistente es un valor "extraño" al conjunto de datos (no atípico).

Una inconsistencia obvia es un valor o combinación de valores que no puede ocurrir en un contexto real: edad negativa, promedio de egreso de preparatoria menor a 60/100 (en México), (sexo=masculino, estado=embarazo), etc.

La detección de valores inconsistentes en un conjunto de datos es particularmente difícil. El conocimiento en el que se basa este proceso debe codificarse en forma de restricciones o reglas de edición. Una forma común de optimizar este proceso es a través de expresiones regulares.

Conclusiones

- El problema de valores faltantes es una fuente común de imperfecciones en los datos.
- En muchos casos, el problema de valores faltantes queda enmascarado por valores por omisión.
- Existen diversas formas de tratar con el problema de valores faltantes, especialmente cuando no representan un alto porcentaje de los datos disponibles.
- Los problemas de valores atípicos y, sobre todo, de valores inconsistentes suelen ser más difíciles de tratar.

Tarea 6

- Analice los problemas de valores faltantes en el conjunto de datos *Pima Indians Diabetes* completo.
- Realice la imputación de los datos utilizando 3 aproximaciones diferentes y compare los resultados.
- Realice una estimación de valores faltantes mediante interpolación.

Fecha de entrega: 24 agosto.